Table d'annotations génomique

Probabilités et statistique pour la biologie (STAT1)

Jacques van Helden 2017-09-21

Contents

But de ce TP

Durant ce TP, vous serez amenés à effectuer les t^âches suivantes:

- 1. Manipuler une table de données génomique (les annotations du génome de la levure).
- 2. Sélectionner un sous-ensemble des données en filtrant les lignes sur base d'un critère déterminé (type d'annotation, chromosome).
- 3. Générer des graphiques pour représenter différents aspects liés à ces données.
- 4. Calculer les estimateurs de tendance centrale et dispersion.
- 5. Calculer un intervalle de confiance autour de la moyenne.

Rendu

A la fin du TP, vous déposerez deux fichiers sur Ametice.

- 1. Votre **code R**.
- 2. Un **rapport d'synthétique** qui inclura une présentation des principaux résultats (figures, statistiques descriptives) et votre interprétation.

Attendus pour le code

- 1. Le code doit être **lisible et compréhensible**: donnez à vos variables des noms indiquant explicitement ce qu'elles contiennent.
- 2. Le code devra être **correctement documenté** (le symbole # en début ou en milieu de ligne indique que le reste de cette ligne est un commentaire).
- avant chaque bloc de code, expliquer ce que vous comptez faire, à quoi sert ce bloc de code;
- si c'st utile, ajoutez quelques mots de commentaires pour justifier l'approche choisi;
- chaque fois que vous déinifissez une variable, ajoutez sur la même ligne un commentaire indiquant ce que cette variable représente.
- 3. Le code doit être **tansportable**: après l'avoir téléchargé, on doit pouvoir l'exécuter sur une autre machine. Je testerai systématiquement si les fichiers de code peuvent ^être exécutés sur ma machine. Evitez donc tout recours à des chemins absolus (nous indiquons ci-dessous comment définir des chemins relatifs par rapport à la racine de votre compte).

Attendus pour le rapport d'interprétation

Le rapport doit être synthétique (1 page de texte maximum + autant de figures et tables que vous le désirez).

Chaque question doit être exprimée explicitement avant de présenter les résultats qui y répondent et de fournir l'interprétation de ces résultats.

Chaque figure ou table doit être documentée par une légende permettant à un lecteur naïf de comprendre ce qu'elle représente. L'interprétation des résultats affichés sur une figure ou table se trouvera dans le texte principal (avec une référence au numéro de figure ou table).

Exemple historique: génome de la levure

- 1992: publication du premier chromosome eucaryote complet, le 3ème chromosome de la levure.
- 1996: publication du génome complet.

Sur base des gènes dU 3ème chromosome (échantillon) on peut estimer la taille moyenne d'un gène de levure.

Questions:

- (a) La moyenne d'échantillon (chromosome III) permettait-elle de prédire la moyenne de la population (génome complet) ?
 - Pour répondre à cette quesiton, nous imaginerons que nous sommes revenus en 1992, et utiliserons l'ensemble des gènes du chromosome III (considérés ici comme un échantillon du génome) pour estimer la taille moyenne des gènes pour l'ensemble du génome (la "population" de gènes").
- (b) Cet échantillon peut-il être qualifié de "simple et indépendant" ?

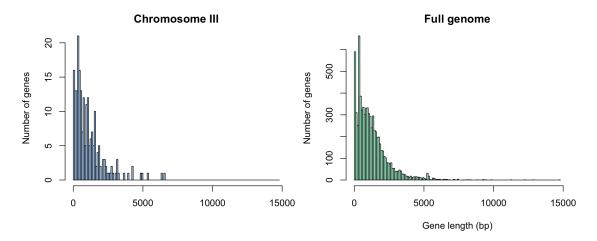


Figure 1: Distribution of gene lengths for Saccharomyces cerevisiae.

Analyse de la longueur des gènes de la levure du boulanger

Tutoriel

Avant de passer aux exercices, nous vous montrons ici quelques éléments de base concernant la lecture, la manipulation et l'écriture des tableaux de données avec R.

Chargement d'un tableau de données

R comporte plusieurs types de structures tabulaires (matrix, data.frame, table).

La structure la plus couramment utilisée est le data.frame, qui consiste en un tableau de valeurs (numériques ou chaînes de caractères) dont les lignes et les colonnes sont associées à des noms.

La fonction read.table() permet de lire un fichier texte contenant un tableau de données, et de stocker le contenu dans une variable.

Plusieurs fonctions dérivées de read.table() facilitent la lecture de différents types de formats:

- read.delim() pour les fichiers dont les colonnes sont délimitées par un caractère particulier (généralement la tabulation, représentée par ";).
- read.csv() pour les fichiers "comma-searated values".
- 1. Téléchargez le fichier suivant sur votre ordinateur:
- Saccharomyces_cerevisiae.R64-1-1.37.gtf
- 2. Chargez-le au moyen de la fonction read.table (pour cela vous devez remplacer le chemin ci-dessous par celui de votre ordinateur).

```
## Read a GTF file with yeast genome annotations
##

## Build the full path to the local file (TO BE ADAPTED FOR YOUR COMPUTER)
gtf.file <- file.path(
    Sys.getenv("HOME"),
    "stat1", "data", "Saccharomyces_cerevisiae",
    "Saccharomyces_cerevisiae.R64-1-1.37.gtf")</pre>
```

```
## Load the feature table
feature.table <- read.delim(gtf.file, comment.char = "#", sep="\t", header=FALSE, row.names=NULL)

## The bed format does not contain any column header,
## so we set it manually based on the description of the format,
## found here:
## http://www.ensembl.org/info/website/upload/gff.html
names(feature.table) <- c("seqname", "source", "feature", "start", "end", "score", "strand", "frame", "...")</pre>
```

Exploration du contenu d'un tableau de données

La première chose à faire après avoir chargé un tableau de données est de vérifier ses dimensions

```
dim(feature.table) ## Dimensions of the tbale

[1] 43028 9

nrow(feature.table) ## Number of rows
```

[1] 43028

```
ncol(feature.table) ## Number of columns
```

[1] 9

L'affichage du tableau d'annotations complet ne serait pas très lisible, puisqu'il comporte des dizaines de milliers de lignes.

Nous pouvons afficher les premières lignes avec la fonction head().

```
## Display the 20 first rows of the feature table
head(feature.table, n = 20)
```

	${\tt seqname}$	source	feature	start	end	score	strand	frame
1	IV	SGD	gene	1802	2953		+	
2	IV	SGD	transcript	1802	2953		+	
3	IV	SGD	exon	1802	2953		+	
4	IV	SGD	CDS	1802	2950		+	0
5	IV	SGD	start_codon	1802	1804		+	0
6	IV	SGD	stop_codon	2951	2953		+	0
7	IV	SGD	gene	3762	3836		+	
8	IV	SGD	transcript	3762	3836		+	
9	IV	SGD	exon	3762	3836		+	
10	IV	SGD	CDS	3762	3833		+	0
11	IV	SGD	start_codon	3762	3764		+	0
12	IV	SGD	stop_codon	3834	3836		+	0
13	IV	SGD	gene	5985	7814		+	
14	IV	SGD	transcript	5985	7814		+	
15	IV	SGD	exon	5985	7814		+	
16	IV	SGD	CDS	5985	7811		+	0
17	IV	SGD	start_codon	5985	5987		+	0
18	IV	SGD	stop_codon	7812	7814		+	0
19	IV	SGD	gene	8683	9756		_	
20	IV	SGD	transcript	8683	9756		_	

1

gene_id YDL248W; transcript_id YDL248W; gene_n

```
gene_id YDL248W; transcript_id YDL248W; exon_number 1; gene_name COS7; gene_sour
4
  gene_id YDL248W; transcript_id YDL248W; exon_number 1; gene_name COS7; gene_source SGD; gene_biotype
                                          gene_id YDL248W; transcript_id YDL248W; exon_number 1; gene_n
                                          gene_id YDL248W; transcript_id YDL248W; exon_number 1; gene_n
                                                                                            gene id YDL2
                                                       gene_id YDL247W-A; transcript_id YDL247W-A; exon
10
                                   gene_id YDL247W-A; transcript_id YDL247W-A; exon_number 1; gene_sour
11
                                                                             gene_id YDL247W-A; transcri
12
                                                                             gene_id YDL247W-A; transcri;
13
14
                                                         gene_id YDL247W; transcript_id YDL247W; gene_n
15
                       gene_id YDL247W; transcript_id YDL247W; exon_number 1; gene_name MPH2; gene_sour
16 gene_id YDL247W; transcript_id YDL247W; exon_number 1; gene_name MPH2; gene_source SGD; gene_biotype
17
                                          gene_id YDL247W; transcript_id YDL247W; exon_number 1; gene_n
18
                                          gene_id YDL247W; transcript_id YDL247W; exon_number 1; gene_n
19
20
                                                         gene_id YDL246C; transcript_id YDL246C; gene_n
```

La fonction tail() affiche les dernières lignes:

3

5

6

7 8

9

Display the 20 first rows of the feature table tail(feature.table, n = 20)

	seqname	source	feature	start	end	score	strand	fram
4300	9 Mito	Ensembl_Fungi	transcript	78533	78605		+	
4301	O Mito	Ensembl_Fungi	exon	78533	78605		+	
4301	1 Mito	SGD	gene	79213	80022		+	
4301	2 Mito	SGD	transcript	79213	80022		+	
4301	3 Mito	SGD	exon	79213	80022		+	
4301	4 Mito	SGD	CDS	79213	80019		+	0
4301	5 Mito	SGD	start_codon	79213	79215		+	0
4301	6 Mito	SGD	stop_codon	80020	80022		+	0
4301	7 Mito	SGD	gene	85035	85112		+	•
4301	8 Mito	SGD	transcript	85035	85112		+	•
4301	9 Mito	SGD	exon	85035	85112		+	•
4302	O Mito	SGD	gene	85295	85777		+	•
4302	1 Mito	SGD	transcript	85295	85777		+	•
4302	2 Mito	SGD	exon	85295	85777		+	•
4302	3 Mito	SGD	gene	85554	85709		+	•
4302	4 Mito	SGD	transcript	85554	85709		+	•
4302	5 Mito	SGD	exon	85554	85709		+	•
4302	6 Mito	SGD	CDS	85554	85706		+	0
4302	7 Mito	SGD	start_codon	85554	85556		+	0
4302	8 Mito	SGD	stop_codon	85707	85709		+	0

```
43009
                                                     gene_id ENSRNA049602365; transcript_id ENSRNA04960
          gene_id ENSRNA049602365; transcript_id ENSRNA049602365-T1; exon_number 1; gene_name tRNA-Val;
43010
43011
43012
                                                          gene_id Q0275; transcript_id Q0275; gene_name
                          gene_id Q0275; transcript_id Q0275; exon_number 1; gene_name COX3; gene_sourc
43013
43014 gene_id Q0275; transcript_id Q0275; exon_number 1; gene_name COX3; gene_source SGD; gene_biotype
                                           gene_id Q0275; transcript_id Q0275; exon_number 1; gene_name
43015
43016
                                           gene_id Q0275; transcript_id Q0275; exon_number 1; gene_name
```

43017

```
43018
43019
                                                                          gene_id tM(CAU)Q2; transcript_i
43020
43021
43022
                                                                                        gene_id RPM1; tran
43023
43024
                                                                                                   gene_id
                                                                  gene_id Q0297; transcript_id Q0297; exo
43025
43026
                                             gene_id Q0297; transcript_id Q0297; exon_number 1; gene_sou
43027
                                                                                    gene_id Q0297; transcr
43028
                                                                                    gene_id Q0297; transcr
```

If you are using the **RStudio** environment, you can display the table in a dynamic viewer pane with the function View().

```
## In RStudio, display the table in a separate tab
View(feature.table)
```

Sélection de sous-ensembles d'un tableau

Sélection d'une ligne par son indice.

feature.table[12,]

12 gene_id YDL247W-A; transcript_id YDL247W-A; exon_number 1; gene_source SGD; gene_biotype protein_cod Sélection d'une colonne par son indice (affichage des premières valeurs seulement.

head(feature.table[,3])

[1] gene transcript exon CDS start_codon stop_codon Levels: CDS exon gene start_codon stop_codon transcript

Selection d'une cellule par indices de ligne et colonne.

feature.table[12, 3]

[1] stop_codon

Levels: CDS exon gene start_codon stop_codon transcript

Sélection d'un bloc de colonnes et/ou de lignes.

feature.table[100:105, 1:6]

	seqname	source	feature	start	end	score
100	IV	SGD	CDS	34240	36477	
101	IV	SGD	start_codon	36475	36477	
102	IV	SGD	stop_codon	34237	34239	
103	IV	SGD	gene	36797	38173	
104	IV	SGD	transcript	36797	38173	
105	IV	SGD	exon	36797	38173	

Sélection de colonnes "à la carte" (ici, les coordonnées génomiques de chaque "feature"): chromosome, début, fin, brin.

feature.table[100:105, c(1,4,5,7)]

```
seqname start end strand
100 IV 34240 36477 -
101 IV 36475 36477 -
102 IV 34237 34239 -
103 IV 36797 38173 +
104 IV 36797 38173 +
105 IV 36797 38173 +
```

Sélectionner une colonne sur base de son nom.

```
## Select the "start" column and print the 100 first results
head(feature.table$start, n=100)
      1802 1802 1802 1802 1802 2951
                                                            3762
                                           3762
                                                3762
                                                      3762
  [1]
            5985 5985 5985
                              5985
                                    5985
                                           7812
                                                 8683
                                                       8683
 [12]
 [23]
      9754 8683 11657 11657 11657 11660 13358 11657 16204 16204 16204
 [34] 16204 16204 17224 17577 17577 17577 17580 18564 17577 18959 18959
 [45] 18959 18959 18959 19310 20635 20635 20635 20635 20635 21004 22471
 [56] 22471 22471 22474 22606 22471 22823 22823 22823 22823 22823 25874
 [67] 26403 26403 26403 26406 28773 26403 28985 28985 28985 28988 30452
 [78] 28985 30657 30657 30657 30657 30657 31827 32296 32296 32296 32296
 [89] 32296 33232 33415 33415 33415 33418 33916 33415 34237 34237 34237
[100] 34240
```

Print the 20 first values of the "feature" field, which indicates the feature type head(feature.tablefeature, n=20)

```
[1] gene transcript exon CDS start_codon
[6] stop_codon gene transcript exon CDS
[11] start_codon stop_codon gene transcript exon
[16] CDS start_codon stop_codon gene transcript
Levels: CDS exon gene start_codon stop_codon transcript
```

Sélection de plusieurs colonnes sur base de leurs noms.

```
## Select the "start" column and print the 100 first results
feature.table[100:106, c("seqname", "start", "end", "strand")]
```

```
segname start
                     end strand
100
         IV 34240 36477
         IV 36475 36477
101
102
         IV 34237 34239
         IV 36797 38173
103
104
         IV 36797 38173
105
         IV 36797 38173
         IV 36797 38170
106
```

Note: il est également possible de nommer les lignes d'un data.frame mais le tableau GTF ne se prête pas à cela. Nous verrons d'autres exemples ultérieurement.

Sélection d'un sous-ensemble de lignes sur base du contenu d'une colonne

```
## Select subset of features having "gene" as "feature" attribute
genes <- subset(feature.table, feature=="gene")
nrow(feature.table) ## Count the number of features</pre>
```

[1] 43028

```
nrow(genes) ## Count the number of genes
```

[1] 7445

Décompte par valeur

La fonction table() permet de compter le nombre d'occurrences de chaque valeur dans un vecteur ou un tableau. Quelques exemples d'utilisation ci-dessous.

```
## Count the number of featues per chromosome
table(feature.table$seqname)
```

```
I II III IV IX Mito V VI VII VIII X XI XII XIII XIV 759 2912 1210 5374 1567 327 2159 946 3856 2054 2617 2231 3789 3311 2774 XV XVI 3846 3296
```

```
## Count the number of features per type
table(feature.table$feature)
```

```
CDS exon gene start_codon stop_codon transcript 7050 7872 7445 6700 6516 7445
```

On peut calculer des tables de contingence en comptant le nombre de combinaisons entre 2 vecteurs (ou 2 colonnes d'un tableau).

```
## Table with two vectors
table(feature.table$feature, feature.table$seqname)
```

```
I II III IV IX Mito
                                       V VI VII VIII
                                                        X XI XII XIII
CDS
            122 492 194 895 255
                                  59 345 151 619
                                                  346 422 361 615
                                                                   544
            137 525 224 961 288
                                  94 400 180 710
                                                  373 480 404 698
                                                                   610
exon
            132 494 213 914 274
                                                  349 458 388 658
gene
                                  62 383 167 676
                                                                   573
start_codon 119 464 185 853 243
                                  28 328 143 593
                                                  325 406 348 586
                                                                   514
stop_codon 117 443 181 837 233
                                  22 320 138 582
                                                  312 393 342 574
                                                                   497
transcript 132 494 213 914 274
                                  62 383 167 676
                                                  349 458 388 658
            XIV XV XVI
CDS
            458 623 549
            500 689 599
exon
gene
            475 665 564
start_codon 438 607 520
stop_codon 428 597 500
transcript 475 665 564
```

```
## Same result with a 2-column data frame
table(feature.table[, c("feature", "seqname")])
```

	seqna	ame												
feature	I	II	III	IV	IX	${\tt Mito}$	V	VI	VII	VIII	X	XI	XII	XIII
CDS	122	492	194	895	255	59	345	151	619	346	422	361	615	544
exon	137	525	224	961	288	94	400	180	710	373	480	404	698	610
gene	132	494	213	914	274	62	383	167	676	349	458	388	658	573

```
start codon 119 464 185 853 243
                                    28 328 143 593 325 406 348 586
  stop_codon 117 443 181 837 233
                                    22 320 138 582
                                                    312 393 342 574
                                                                     497
  transcript 132 494 213 914 274
                                    62 383 167 676
                                                   349 458 388 658
             seqname
feature
              XIV XV XVI
  CDS
              458 623 549
  exon
              500 689 599
  gene
              475 665 564
  start_codon 438 607 520
  stop_codon
             428 597 500
  transcript
             475 665 564
```

Exercices

1. Spécifications du format GTF

Lisez les spécifications du format GTF.

- Ensembl (http://www.ensembl.org/info/website/upload/gff.html)
- UCSC (https://genome.ucsc.edu/FAQ/FAQformat.html#format4)

2. Création d'un dossier local pour le TP

Créez un dossier local (par exemple: stat1/TP_levure à partir de la racine de votre compte). Nous vous suggérons d'utiliser les fonctions suivantes:

- Sys.getenv("HOME") (Linnux et Mac OS X), pour obtenir la racine de votre compte utilisateur;
- file.path() pour construire un chemin;
- dir.create() pour créer le dossier de ce TP. Lisez attendivement les options de cette fonction avec help(dir.create)

3. Localisation du fichier d'annotations

Localisez le fichier d'annotations du génome de la levure en format GTF dans ce dossier local.

- Site Ensembl Fungi: http://fungi.ensembl.org/
- Cliquez "Downloads" pour accéder au site ftp
- Dans la boîte de recherche, tapez "saccharomyces cerevisiae" et suivez le lien "GTF"
- COpiez l'adresse (URL) du ichier Saccharomyces_cerevisiae.R64-1-1.37.gtf.gz

4. Téléchargement d'un fichier à partir d'un site ftp

Fonctions suggérées:

• download.file() (lisez l'aide pour conna tre les arguments)

5. Chargement d'une table de données en R

Ecrivez un script qui charge la table de données dans une variable nommée feature.table, en utilisant la fonction R read.delim().

Veillez à ignorer les lignes de commentaires (qui commencent par un caractère #).

5. Calcul de la longueur des gènes

- Ajoutez à la table une colonne intitulée "length" qui indique la longueur de chaque élément génomique annoté.
- Comptez le nombre de lignes de la table correspondant à chaque type d'annotation (3ème colonne du GTF, "feature").
 - fonction table()
- Sélectionnez les lignes correspondant à des gènes.
 - fonction subset()
- Comptez le nombre de gènes par chromosome.
 - fonction table()
- Chargez la table des tailles de chromosomes chrom_sizes.tsv, et calculez la densité de gènes pour chaque chromosome (nombre de gènes par Mb).

6. Histogramme de la longueur des gènes

Au moyen de la fonction hist(), dessinez un histogramme représentant la distribution de longueur des gènes. Choisissez les intervalles de classe de façon à ce que l'histogramme soit informaatif (ni trop ni trop peu de classes).

Récupérez le résultat de hist() dans une variable nommée gene.length.hist.

Imprimez le résultat à l'écran (print()) et analysez la structure de la variable gene.length.hist (il s'agit d'une variable de type liste).

Fonctions utiles:

- class(gene.length.hist)
- attributes(gene.length.hist)

7. Paramètres descriptifs

Calculez les paramètres de tendance centrale (moyenne, médiane, mode) et de dispersion (variance, écart-type, écart inter-quartile)

- pour les gènes du chromosome III;
- pour l'ensemble des gènes de la levure.

Affichez ces paramètres sur l'histogramme de la longueur des gènes, en utilisant la fonction arrows()

8. Intervalle de confiance

A partir des gènes du chromosome III (considérés comme l'échantillon disponible en 1992), calculez un intervalle de confiance autour de la moyenne, et formulez l'interprétation de cet intervalle de confiance. Evaluez ensuite si cet intervalle de confiance recouvrait ou non la moyenne de la population (tous les gènes du génome de la levure, qui devint disponible 4 ans après le chromosome III).

9. Distribution de la longueur des gènes

- A partir du résult de hist(), récupérez un tableau (dans une variable de type data.frame) indiquant les fréquences absolues (count) en fonction de la taille médiane des classes (mids),
- Ajoutez à ce tableau une colonne indiquant la fréquence relative de chaque classe de longueurs de gènes.
- Ajoutez à ce tableau des colonnes indiquant la fonction de répartition empirique des longueuurs de gènes (nombre de gènes d'une taille inférieure ou égale à chaque valeur x observée, et fréquence relative de ce nombre).
 - fonction de base: cumsum()
 - fonction avancée:ecdf()
- Au moyen des fonctions plot() et lines(), dessinez un graphe représentant la fréquence absolue par classe (médianes de classes en X, comptages en Y), et la fonction de répartition empirique.
 - suggestion: superposez les utilisez le type de lignes "h" pour les fréquences de classe, et "l" ou "s" pour la fonction de répartition.

10. Distribution attendue au hasard pour la longueur des gènes

Sur base de la taille du génome (12.156.679 bp) et des fréquences génomiques de codons définies ci-dessous, calculez la distribution de longueurs de gènes attendue au hasard, et ajoutez-là au graphique.

Vous pouvez télécharger les fréquences génomiques de tous les trinucléotides ici: 3nt_genomic_Saccharomyces_cerevisiae-ovlp-1str.tab

Alternative: créez une variable freq.3nt et assignez-y manuellement les valeurs pour les 4 nucléotides nécessaires, à partir de la table ci-dessous.

sequence	frequency	occurrences
AAA	0.0394	478708
ATG	0.0183	221902
TAA	0.0224	272041
TAG	0.0129	156668
TGA	0.0201	244627

11. Avant de terminer : conservez la trace de votre session

La traçabilité constitue un enjeu essentiel en sciences. La fonction R sessionInfo() fournit un résumé des conditions d'une session de travail: version de R, système opérateur, bibliothèques de fonctions utilisées.

sessionInfo()

```
R version 3.3.2 (2016-10-31)
```

Platform: x86_64-apple-darwin13.4.0 (64-bit)

Running under: macOS Sierra 10.12.6

locale:

[1] en_US.UTF-8/en_US.UTF-8/en_US.UTF-8/C/en_US.UTF-8/en_US.UTF-8

attached base packages:

[1] stats graphics grDevices utils datasets methods base

other attached packages:

[1] knitr_1.17

loaded via a namespace (and not attached):

- [1] backports_1.1.0 magrittr_1.5 rprojroot_1.2 tools_3.3.2 [5] htmltools_0.3.6 yaml_2.1.14 Rcpp_0.12.12 stringi_1.1.5
- [9] rmarkdown_1.6 highr_0.6 stringr_1.2.0 digest_0.6.12
- [13] evaluate_0.10.1

Rendu